

000
001
002
003
004
005
006
007
008
009
010
011
012
013
014
015
016
017
018
019
020
021
022
023
024
025
026
027
028
029
030
031
032
033
034
035
036
037
038
039
040
041
042
043
044
045
046
047
048
049
050
051
052
053
054

基于监督学习与副露偏置校准的国标麻将智能体

姓名：王子恒 学号：2500013197

Abstract

本文总结 Botzone 国标麻将智能体从课程 baseline 到最终 V7+call150 的版本迭代。项目没有只追求单次训练准确率，而是围绕状态特征、网络结构、训练目标、部署稳定性和推理偏好逐步调整。最终版本继承 V7 calibrated 的残差卷积策略网络，并在推理阶段对吃、碰、明杠响应动作加入轻量 logits 偏置。V7 在验证集达到 $\text{top1}=0.8843$ 、 $\text{top3}=0.9924$ 、 $\text{top5}=0.9987$ 、副露 $\text{F1}=0.9239$ ；V7+call150 在 960 局 2v2 中相对 V7 base 获得团队小分 +480，因此作为最终提交版本。

1. 任务建模与数据

国标麻将是四人、不完美信息、长时序且收益高方差的博弈问题。Botzone 每次只要求当前玩家在可见信息下输出一个合法动作，因此本项目将其近似为带合法动作掩码的离散动作分类问题。这个建模方式不能完整表达长期博弈价值，但非常适合利用专家牌谱进行监督学习，并且可以通过本地自对战进一步筛选真实强度。

动作空间统一为 235 类：Pass、Hu、34 种 Play、63 种 Chi、34 种 Peng、34 种 Gang、34 种 AnGang 和 34 种 BuGang。模型输出 logits 后加上 action mask 的对数屏蔽，非法动作被压到极小值，从而保证最终 argmax 只会选择合法动作。课程数据 README 说明 data.txt 包含 98209 场对局，预处理后约得到 5865816 条决策样本。

2. 版本迭代路线

项目路线可以概括为：先让 baseline 正常学习动作，再补充可见局面特征；随后提高网络表达能力；再加入副露、价值和蒸馏相关训练；最后通过推理阶段轻量校准解决 V7 的保守倾向。每一代都依赖上一代已验证资产，并通过离线指标与自对战共同判断是否保留。

Table 1. 版本迭代中的算法继承与调整。

版本	算法与结论
Baseline	原始 SL 框架，基础牌面特征 + 简单 CNN，做 235 类动作分类。作用是建立数据、训练、评估和 Botzone 输出闭环。
V2	继承监督学习范式，输入扩展为 18x4x9，加入历史牌、副露、牌墙等信息，主要解决信息不足。
V3/V4	继承 V2 特征，改为残差 CNN + SE 通道注意力，并加入花色置换增强，提升泛化。
V6 refine2	继承残差 CNN，引入蒸馏、价值相关训练和副露专项调参，并通过自对战筛选。
V7 calibrated	从 V6 refine2 初始化，使用 policy CE、蒸馏 KL、动作类型头和价值头做多任务微调。
V7+call150	不改权重，在推理阶段给 Chi/Peng/Gang 响应 logits 加偏置，解决 V7 略保守问题，最终采用。
V8a	尝试硬蒸馏 call150 行为：离线 top1 更高，但实战点炮和小分更差，因此放弃。

3. 最终模型结构

最终网络定义在 model_v6.py 的 CNNModel。输入是 18 通道、4x9 的 observation；4x9 对应麻将牌的二维排列，18 个通道分别承载门风、场风、手牌、已见牌、牌墙、当前牌、历史出牌、副露和标志位等信息。这种表示方式把麻将状态压成小型多通道图像，使卷积网络可以学习同花色相邻牌、对子、顺子和副露结构。

网络首先用 3x3 Conv2d 将输入映射到 160 个特征通道，再堆叠 8 个 ResidualBlock。每个残差块由两层卷积、BatchNorm、ReLU 和 Squeeze-Excite 通道注意力组成。残差连接让更深网络更容易优化，SE 结构让模型自动强调当前局面中更重要的特征通道。卷积输出展平后进入 1024 维全连接 neck，并分成 policy、type、value 三个 head。

3.1. 代码实现对应关系

特征工程主要在 feature_v2.py 中实现。FeatureAgent 维护手牌、副露、历史出牌、已见牌和牌墙状态；request2obs 根据 Botzone 请求更新内部状态，_obs 将状态 reshape 为 18x4x9 observation，并同步生成 235 维 action_mask。action2response 和 response2action 则负责在模型动作编号与 Botzone

字符串之间互相转换。

模型前向在 model_v6.py 的 forward_all 中完成。它先归一化部分计数通道，再经过卷积残差网络得到隐藏向量，最后输出 policy logits、type logits 和 value。其中 action_mask 通过 clamp(log(mask)) 加到 logits 上，mask 为 0 的非法动作会变成极小分数，mask 为 1 的合法动作保持不变。

4. 训练目标

V7 calibrated 从 V6 refine2 checkpoint 初始化，训练损失由四部分组成：policy loss、distill loss、type loss 和 value loss。policy loss 是专家动作交叉熵；distill loss 使用 KL 散度约束新模型不要破坏旧强模型；type loss 强化 Pass、Play、Chi、Peng 等粗粒度动作判断；value loss 用收益信号约束隐藏表示。训练还使用花色置换增强，利用万、条、筒三门花色的对称性提升泛化。

训练算法的核心可以写为 $L = L_{\text{policy}} + \lambda_d L_{\text{distill}} + \lambda_t L_{\text{type}} + \lambda_v L_{\text{value}}$ 。与只做单一监督学习相比，多任务训练能让模型同时保留专家动作模仿能力、旧模型稳定性、动作类型判断能力和局面收益敏感性。

优化器使用 AdamW，并配合 cosine 学习率调度和梯度裁剪，降低后期微调时破坏已有策略的风险。训练选择不是只看最低 loss，还会观察 top1/top3/top5、副露 F1、不同动作类型准确率和后续自对战表现。这个选择标准比单纯保存验证集 top1 最优模型更贴近比赛目标。

5. Botzone 部署与 call150 校准

最终 Botzone 入口在 __main__.py。程序启动后从 data/mahjong_v7_calibrated_best.pkl 加载权重，FeatureAgent 将 Botzone 请求转成 observation 和 action mask，模型前向计算动作 logits，再由 action2response 转回协议字符串。副露后的 Chi/Peng 输出还需要额外选择弃牌，这部分由 _prepare_meld_response 处理。

V7+call150 没有重新训练权重，而是在存在响应机会时对 Chi、Peng、Gang 区间 logits 加偏置：Chi 加 1.50+0.35，Peng 加 1.50+0.35，Gang 加 1.50。该策略继承 V7 的局面理解，只轻微移动副露边界，因此比把偏置硬蒸馏进模型权重更加稳定。

部署阶段还专门处理了 Botzone 长时运行与用户存储空间路径问题。最终无模型代码包只包含 Python 源码，模型权重单独放入 Botzone 的 /data

存储空间，代码运行时读取 data/mahjong_v7_calibrated_best.pkl。这样既满足代码包大小限制，也避免模型加载失败时悄悄 fallback 导致行为异常。

6. 实验结果

Table 2. V7 calibrated 离线验证指标。

指标	数值
top1/top3/top5	0.8843 / 0.9924 / 0.9987
副露 acc/F1	0.9449 / 0.9239
Pass/Play/Chi/Peng	0.9531 / 0.8680 / 0.8915 / 0.9460
Gang/AnGang/BuGang/Hu	0.9261 / 0.8636 / 0.9382 / 1.0000

离线验证主要用于判断模型是否学会专家动作和动作类型。V7 calibrated 的 top3/top5 很高，说明大多数时候正确动作已在候选前列；但 top1 仍不能完全代表比赛强度，所以最终版本必须用自对战筛选。

Table 3. 2v2 自对战结果摘要。每组实验均明确写出对阵双方。

实验	对阵双方	结果
A	960局 2v2: V7+call150 x2 vs V7 base x2	V7+call150: 胜率 24.38%, 小分 +480, 点炮 16.46%; V7 base: 胜率 23.75%, 小分 -480, 点炮 17.08%。
B	480局 2v2: V8a x2 vs V7 base x2	两者胜率均为 25.00%; V8a 小分 -740, 点炮 21.67%; V7 base 小分 +740, 点炮 19.17%。
C	480局 2v2: V8a x2 vs V7+call150 x2	V7+call150 胜率 30.00%, 小分 +2988, 点炮 17.50%; V8a 胜率 18.33%, 小分 -2988, 点炮 20.42%。

实验 A 比较最终推理策略 V7+call150 与原始 V7 base；实验 B 检查 V8a 是否至少强于 V7 base；实验 C 直接比较 V8a 与最终候选 V7+call150。结论是 V7+call150 小幅但稳定优于 V7 base，而 V8a 在两组对战中都不适合作为最终版本。

6.1. 评价协议与赛制近似

本地评估无法完全复刻正式 Botzone 瑞士轮和复式赛制，因此采用短时间可运行的近似：固定多个版本组成 2v2 队伍，统计胡牌率、小分、排名分、点炮率和副露行为。其中小分和点炮率比单纯胜率更敏感，因为国标麻将存在大量荒牌和高方差结算，少量错误副露可能不会立刻改变胡牌数，却会显著影响长期得分。

因此最终选择 V7+call150 的理由不是它在每个离线指标上都最大，而是它在自对战中同时保持较低点炮率和略高团队小分。这与正式比赛目标更一致：模型不仅要能胡牌，也要避免为了短期进攻而频繁送分。

7. 失败实验：V8a 硬蒸馏

V8a 的目标是把 call150 的推理偏置蒸馏进模型参数。训练时使用 V7 logits 加偏置后的 argmax 作为伪标签，并额外推动模型在副

露机会下选择伪标签动作。它的离线指标确实更好， $to_{pl}=0.8911$ ， $call_pred_rate=0.4159$ 。

但对战结果说明该方向失败。V8a 对 V7 base 时胡牌数持平，但小分 -740、点炮率 21.67% 对 19.17%；对 V7+call150 时胜率 18.33% 对 30.00%，小分 -2988。硬蒸馏提高了副露倾向，却损害了副露时机和风险控制。

这个失败说明，麻将策略中的副露不是一个独立的二分类问题。是否吃碰取决于手牌速度、番型潜力、剩余牌、对手危险程度、当前分差和牌墙深度。固定提高副露概率会让模型在部分局面更积极，但也会在需要防守或保持门清价值时过早暴露手牌。

7.1. 当前模型的主要缺陷

从日志和自对战观察看，V7+call150 仍有三个局限。第一，它对局面价值的理解主要来自专家动作和粗粒度收益信号，缺少真正的危险度估计。第二，副露校准是全局常数，不能根据局面动态改变；同样的 Chi/Peng 偏置在快攻局和防守局中并不总是合理。第三，出牌选择虽然离线准确率较高，但仍可能在字牌、终张和危险筋判断上出现与人类经验不一致的情况。

8. 工程可复现性与提交结构

最终提交被拆成三个部分。第一部分是 Botzone 无模型智能体，只包含 `__main__.py`、`agent.py`、`feature_v2.py` 和 `model_v6.py`，模型权重不放入代码包，而是单上传到 Botzone 用户存储空间的数据目录。第二部分是研究性报告，即本文 PDF。第三部分是完整代码和模型，包含最终 Botzone 代码、训练脚本、诊断脚本、自对战脚本、配置文件、评估结果和权重文件。

这种拆分对应了实际部署约束：Botzone 代码包有大小限制，而模型文件约 39.7MB，必须通过存储空间读取。最终入口默认读取 `data/mahjong_v7_calibrated_best.pkl`，并支持通过 `MAHJONG_MODEL_PATH` 环境变量覆盖路径。早期版本曾出现模型路径不一致和 fallback 导致行为异常的问题，最终版本将加载失败视为显式错误，从而便于在 Botzone 日志中快速定位问题。

为了保证结果可追溯，完整代码部分保留了训练摘要、关键自对战 json、诊断日志和 SHA256 清单。虽然训练集本身没有打包进提交文件，但 README 中记录了数据来源、模型文件、Botzone 上传方式和主要评估命令。后续如果需要复现实验，可以从相同预处理数据出发，先加载 V6 refine2 或 V7 checkpoint，再执行多任务微调 and call150 推理校准。

9. 下一代模型的训练路线

如果继续追求显著提升，最值得投入的不是继续盲目增大 CNN，而是改进训练目标。当前监督学习本质上模仿牌谱中的专家动作，但专家动作标签并不直接告诉模型每个动作的长期收益。下一代可以把每局最终小分、胡牌、点炮、被自摸和荒牌状态回填到中间决策样本，用结果加权监督学习或优势加权 imitation learning，让模型更重视真正影响比赛得分的局面。

第二条路线是训练轻量危险度/价值网络。它不一定替代主策略网络，而是作为辅助模块评估弃牌风险、副露收益和防守价值。例如在有副露机会时，主策略给出 Chi/Peng/Gang/Pass 候选，价值网络根据手牌速度、剩余牌、对手副露、已见牌和当前分差估计风险收益，再决定是否提高或降低响应动作分数。这比全局常数 call150 更细致，也能解释 V8a 硬蒸馏为什么会失败。

第三条路线是让本地评估更贴近正式赛制。当前自对战已经比离线准确率更可靠，但仍只是短时间近似。后续可以加入固定牌墙复式评估、座次轮换、瑞士轮积分估计和置信区间统计，减少随机发牌对模型选择的影响。当评估协议更稳定时，模型调参就可以从“看单次胜率”转向“看长期小分、点炮率和排名分的稳健提升”。

10. 关键函数与变量说明

最终智能体的核心变量可以分为三类。第一类是状态变量，例如 `hand`、`packs`、`history`、`shownTiles` 和 `tileWall`，它们分别记录当前手牌、四家副露、四家历史出牌、全局已见牌和剩余牌墙。第二类是编码偏移量，例如 `OFFSET_OBS`、`OFFSET_ACT` 和 `OFFSET_TILE`，它们保证特征张量、动作编号和真实麻将牌之间有稳定映射。第三类是推理校准参数，即 `CALL_BIAS`、`CHI_EXTRA_BIAS` 和 `PENG_EXTRA_BIAS`，它们只影响响应阶段的动作排序，不改变模型权重。

`request2obs` 是 Botzone 协议到模型输入的桥梁。每收到一条请求，它会更新内部局面状态，并在需要当前玩家决策时返回 `observation` 和 `action_mask`。`action_mask` 的意义很重要：模型本身可能给非法动作较高 logits，但加上 `mask` 后非法动作会被压到极小值，最终输出仍满足规则。`obs2response` 则执行反向流程：把 `observation` 转成 `tensor`，调用模型前向，应用 `call150` 偏置，再把动作编号转成 Botzone 字符串。

训练脚本中的 `evaluate` 不只统计整体 `top1`，还记录 `top3`、`top5`、动作类型准确率、副露 F1、字牌相关指标和价值误差。这些指标的作用不同：`top3/top5` 衡量候选质量，副露 F1 衡量响应阶段判断，`value error` 衡量收益估计是否稳

定。因此在选择最终模型时，不应只看一个最高准确率，而要综合判断它是否真的适合比赛。

从工程角度看，V7+call150 的优势在于改动位置很小：它不改变训练数据、不改变模型结构，也不需要重新保存权重，只在部署推理阶段移动副露边界。这种方式便于回滚和调参。若 call150 在 Botzone 实战中表现异常，只需要修改几个 bias 常数即可测试新版本，而不用重新进行长时间训练。

11. 训练失败的启发

项目过程中并非所有训练都带来提升。V8a 是最典型的反例：它试图把推理阶段的 call150 偏置变成模型内部参数，离线指标看似更好，但对战中点炮率和小分变差。这说明训练目标如果过于贴近局部动作标签，可能会牺牲长期收益。麻将中的很多动作在单步看是合理的，放到整局收益上却未必正确。

这个失败也提醒我，监督学习模型的“强度”不是由网络大小单独决定的。更大的模型、更高的 top1 或更积极的副露倾向都不必然带来更强 Bot。真正有价值的优化应当把数据、目标函数、评估协议和部署方式连在一起：训练阶段让模型学会候选动作，评估阶段验证长期得分，部署阶段再做少量、可解释、可回滚的策略校准。

12. 总结与开放方向

最终 V7+call150 的核心经验是：先用特征和网络结构提高候选动作质量，再用自对战调节策略偏好。离线准确率保证模型基本能力，自对战指标决定是否真正部署。后续可以继续做三件事：第一，基于最终小分、胡牌和点炮事件对样本加权；第二，训练专门的轻量价值/危险度网络，辅助副露和弃牌选择；第三，把本地评估器进一步贴近正式瑞士轮和复式赛制，减少模型选择与比赛目标之间的偏差。

References

- [1] Botzone Chinese Standard Mahjong Platform, <https://botzone.org.cn>.
- [2] PyTorch Documentation, <https://pytorch.org/docs/stable/>.
- [3] K. He, X. Zhang, S. Ren, and J. Sun. Delving Deep into Rectifiers: Surpassing Human-Level Performance on ImageNet Classification. ICCV, 2015.